# Büyük Veri Tahmin Modelleri İçin Derin Öğrenme

Derin öğrenme, yapay zeka ve makine öğreniminde karmaşık tahmin modellerinin öğrenilmesini sağlayan yeni bir paradigmadır. Özellikle görüntü analizi ve konuşma tanımadaki devrim niteliğindeki sonuçlar, bu alanın büyük veri içeren birçok farklı disipline uygulanmasını tetiklemiştir.

Temel bulguları şunlardır:

- **Modüler Yapı:** Derin öğrenme modelleri, "Lego" parçaları gibi esnek bir şekilde birleştirilebilen temel mimari bloklardan oluşur.
- **Tarihsel Dönüşüm:** 1940'larda başlayan süreç, 2006 yılındaki "Deep Belief Networks" (Derin İnanç Ağları) atılımıyla üçüncü dalgasına girmiş ve günümüzdeki popülaritesine ulaşmıştır.
- **Öğrenme Mekanizmaları:** Modeller, denetimli ve denetimsiz öğrenme stratejilerinin kombinasyonunu kullanarak veri temsilini gerçekleştirir.
- **Veri Gereksinimi:** Derin öğrenme modelleri "mucize" yaratmaz; yüksek doğruluk için on binlerce örneğe ihtiyaç duyarlar (örneğin, EMNIST veri setinde %5 hata payının altına düşmek için 25.000'den fazla örnek gereklidir).

## 1. Derin Öğrenmenin Tarihsel Gelişimi

Sinir ağlarının gelişimi, 1940'lardan bugüne uzanan inişli çıkışlı bir sürece sahiptir. Önemli dönüm noktaları aşağıda kronolojik olarak sunulmuştur:

| Yıl | Gelişme | Önemli İsimler |
|---|---|---|
| **1943** | İlk matematiksel nöron modeli | McCulloch ve Pitts |
| **1957** | Perceptron (Tek katmanlı sinir ağı) | Rosenblatt |
| **1969** | XOR sorununun çözülememesi ve "Yapay Zeka Kışı" | Minsky ve Papert |
| **1980** | Neocognitron (Modern CNN'lerin öncüsü) | Fukushima |
| **1991** | Kaybolan/Patlayan Gradyan Sorunu (Vanishing Gradient) | Hochreiter |
| **1997** | Long Short-Term Memory (LSTM) modelinin tanıtılması | Hochreiter ve Schmidhuber |
| **2006** | Derin İnanç Ağları ve "Derin Öğrenme" teriminin popülerleşmesi | Hinton ve ark. |
| **2014** | Üretken Çekişmeli Ağlar (GANs) | Goodfellow ve ark. |
| **2019** | Turing Ödülü | Bengio, Hinton ve LeCun |

# 2. Temel Sinir Ağı Mimarileri

## 2.1. Derin İleri Beslemeli Sinir Ağları (D-FFNN)

En basit mimari yapısıdır. Veri, giriş katmanından çıkış katmanına doğru döngü oluşturmadan ilerler.

- **Evrensel Yaklaşım Teoremi:** Bir gizli katmana sahip ileri beslemeli bir ağın herhangi bir sürekli fonksiyonu taklit edebileceğini savunur.
- **Derinlik Avantajı:** Pratik uygulamalarda, çok sayıda katman (derinlik) kullanımı öğrenilebilirliği kolaylaştırır ve gizli birimlerin genişliğinin aşırı büyümesini engeller.

## 2.2. Evrişimli Sinir Ağları (CNN)

Özellikle görüntü işleme ve bilgisayarlı görü alanında baskındır.

- **Yerel Bağlantısallık ve Ağırlık Paylaşımı:** Her nöronun tüm girişlere bağlanması yerine sadece yerel alanlara bağlanması, parametre sayısını dramatik şekilde düşürür.
- **Temel Bileşenler:** Evrişim (Convolution) katmanı, Havuzlama (Pooling) katmanı ve Tam Bağlantılı (Fully-Connected) katman.
- **Önemli Varyantlar:**
    - **VGGNet:** Derinliğin performans üzerindeki etkisini incelemiş, 19 katmana kadar çıkmıştır.
    - **GoogLeNet (Inception):** Hesaplama maliyetini düşük tutmak için paralel katmanlar ve 1x1 evrişimler kullanır.
    - **ResNet:** "Residual" (artık) bloklar aracılığıyla 152 katmana kadar derinleşebilen ağlarda performans kaybını (degradasyon) önler.

## 2.3. Derin İnanç Ağları (DBN)

Kısıtlanmış Boltzmann Makinelerinin (RBM) üst üste istiflenmesiyle oluşur.

- **Eğitim Stratejisi:** Önce denetimsiz "açgözlü katman bazlı ön eğitim" (greedy layer-wise pre-training) ile parametreler başlatılır, ardından denetimli bir yöntemle ince ayar (fine-tuning) yapılır.

## 2.4. Otomatik Kodlayıcılar (Autoencoders - AE)

Boyut indirgeme ve özellik seçimi için kullanılan denetimsiz modellerdir. Giriş verisini daha düşük boyutlu bir koda ($c = h(x)$) dönüştürür ve ardından bu koddan orijinal veriyi ($x \approx y = g(c)$) yeniden üretmeye çalışır.

## 2.5. Uzun Kısa Süreli Bellek (LSTM)

Tekrarlayan Sinir Ağlarının (RNN) uzun vadeli bağımlılıkları yönetememe sorununu çözer.

- **Kapı Mekanizması:** Giriş, unutma (forget) ve çıkış kapıları aracılığıyla bilginin hücre içindeki akışı kontrol edilir.

- **CEC (Constant Error Carousel):** Gradyan patlaması veya kaybolması sorununu engelleyerek ağın uzun zaman aralıklarındaki bilgileri "hatırlamasını" sağlar.

# 3. Öğrenme Algoritmaları ve Metodoloji

Derin öğrenme modellerinin başarısı, optimize edilmiş öğrenme kurallarına dayanır:

- **Geri Yayılım (Backpropagation):** Hata sinyalini çıkıştan girişe doğru yayarak ağırlıkların güncellenmesini sağlar.
- **Stokastik Gradyan İnişi (SGD):** Büyük veri setlerinde hızı artırmak için rastgele seçilen küçük veri grupları üzerinden gradyan hesaplar.
- **iRprop+:** Geri yayılımı hızlandırmak için sadece türevin işaretini kullanan ve ağırlık geri takibi (weight-backtracking) yapan gelişmiş bir algoritmadır.
- **Karşılaştırmalı Sapma (Contrastive Divergence - CD):** RBM modellerinde gradyan tahmini için Gibbs örneklemesi kullanan hızlı bir yöntemdir.

# 4. Kritik Tartışmalar ve Uygulama Zorlukları

## 4.1. Büyük Veri vs. Küçük Veri

Derin öğrenme modelleri veri yoğun yöntemlerdir. Metin, görüntü veya ses gibi farklı veri tiplerinde "bir örneğin" bilgi içeriği aynı değildir. Raporun sunduğu deneysel veriler, modelin başarısının doğrudan veri miktarıyla ilişkili olduğunu kanıtlamaktadır.

- **Önemli Bulgul:** EMNIST rakam sınıflandırma görevinde, hata oranını %5 referans çizgisinin altına indirmek için en az 25.000 eğitim örneği gerekmektedir. Örnek sayısı yetersiz olduğunda derin öğrenme yöntemleri çökmektedir.

## 4.2. "Kara Kutu" ve Açıklanabilirlik

Derin öğrenme modelleri genellikle tahmin odaklı "kara kutu" modelleridir; yani çıkarımsal (inferential) veya yorumlanabilir bir yapı sunmazlar. Ancak klinik ve tıbbi alanlarda kararların anlaşılabilir olması gerektiğinden, "Açıklanabilir Yapay Zeka" (XAI) alanı bu ihtiyaca yönelik gelişmektedir.

## 4.3. Uygulama Alanları

| Veri Tipi | Uygulama Örneği | Mimari |
|---|---|---|
| **Görüntü** | Cilt kanseri sınıflandırması, Akciğer kanseri prognozu | CNN |
| **Metin** | Duygu analizi, Dil çevirisi, İlaç etkileşimi çıkarma | LSTM, CNN |
| **Ses** | Akustik modelleme, Konuşma tanıma | DBN, LSTM |
| **Genomik** | Gen ifadesi verilerinin sınıflandırılması | DBN |

# 5. Sonuç

Derin öğrenme, yapay zekanın geleceğini şekillendiren modüler ve esnek bir yapıdır. Mevcut modeller, veri bilimcilerin araç çantasında bulunması gereken temel yapı taşlarını oluşturur. Ancak bu modellerin başarısı; doğru mimari seçimi, yeterli veri miktarı ve karmaşık matematiksel optimizasyonların doğru uygulanmasına sıkı sıkıya bağlıdır. Gelecekteki AI gelişmeleri, bu temel blokların daha karmaşık ve uygulamaya özel şekillerde birleştirilmesine dayanacaktır.

İREM ŞİMŞEK

02220224560